



Projet 3

Préparer les données pour un organisme de santé publique

Guillaume LAFON



Sommaire

- 1 Introduction
- 2 Exploration du jeu de données
- 3 Analyse exploratoire
- 4 Conclusion



Introduction

1 Introduction



1.1 Contexte

Proposer une méthode d'autocomplétion pour ajouter les informations d'un produit dans la base de données OpenFoodFact de l'Agence de santé Française.

Mon objectif: Obtenir un jeu de données complet, représentatif des différents types de produits, et prêt à être exploité par un algorithme de suggestion, sans valeurs nutritionnelles manquantes.

1.2 Données

Jeu de données sur les produits alimentaires du monde entier. Base de données issue de OpenFoodFacts

1.3 Mission

Formulation de la problématique :

- Nettoyer et explorer les données.
- Sélectionner les champs de données pertinents pour caractériser un produit.

1 Introduction



Application :

- Scanner
- Saisir les valeurs nutritives (Seuils limites fixés par l'algorithme)



← Modifier aliment		↻	↓	✓
Portion	100			
Portion (Unité)	g			
Notes				
Nutrition				^
Kilocalories (kcal)	373			
Lipides (g)	29			
Acides gras saturés (g)	21			
Glucides (g)	1			
Sucres (g)	0			
Fibres (g)	0			
Protéines (g)	27			
Sel (g)	0,83			



2 Exploration du jeu de données



2 Exploration du jeu de données

162 colonnes et 320772 lignes

- Informations générales (code bar, date de création, nom, marque, catégories, pays de vente...)
- Qualité du produit (nutriscore)
- Composition du produit (additifs, ingrédients, nutriments)




2 Exploration du jeu de données

- **Approche empirique pour conserver les caractéristiques produits**
 - **Informations générales:**
 - Code Barre et le nom du produit (code, product_name) sans doublons
 - Origine du produit : Produits vendu uniquement en France (countries = fr)
 - **Catégories du produit :**
 - Pnns_groups_1 (Programme national de santé)
 - **Valeurs nutritives :**
 - Valeurs notées sur les emballages alimentaires et prises en compte lors du calcul du Nutriscore
energy_100g, saturated-fat_100g, fat_100g, fiber_100g, proteins_100g, sodium_100g, sugars_100g



2 Exploration du jeu de données

- Valeurs manquantes





2 Exploration du jeu de données

- Valeurs aberrantes

- Teneur des valeurs nutritives entre 0 et 100g
- Énergie par produit entre 0 et 4000kJ.

➡ Suppression des valeurs par des NAN

➡ Suppression des produits dont la somme des valeurs nutritives dépasse 100g


➡ Suppression des produits sans catégories pnns_groups_1

Le jeu de données contient désormais **49304** lignes



2 Exploration du jeu de données

- Imputation des valeurs manquantes






2 Exploration du jeu de données

- Imputation des valeurs manquantes
- Ne rien faire → Si le nombre de manquant est faible.
- Supprimer les produits avec des manquants → L'échantillon peut devenir trop faible
- Méthode d'imputation simple (mode, médiane, moyenne) pour les mêmes types de produit.
- Remplacer les valeurs manquantes par prévision statistique (knnImputer ou iterativelyImputer)

2 Exploration du jeu de données


- Imputation des valeurs manquantes






2 Exploration du jeu de données

- Imputation des valeurs manquantes




2 Exploration du jeu de données

- Imputation des valeurs manquantes




2 Exploration du jeu de données

- Imputation des valeurs manquantes




2 Exploration du jeu de données

- Imputation des valeurs manquantes




2 Exploration du jeu de données

- Imputation des valeurs manquantes



2 Exploration du jeu de données

- Imputation des valeurs manquantes





2 Exploration du jeu de données

- Méthodes d'imputations utilisées
- Méthode d'imputation simple (médiane) : energy_100g, proteins_100g, sodium_100g et sugars_100g
- knnImputer : fat_100g et saturated-fat_100g
- iterativelyImputer : fiber_100g

2 Exploration du jeu de données

- Validation de la méthode d'imputations utilisées

# energy_100g	
count	39846.0
mean	996.0
std	701.0
min	0.0
25%	368.0
50%	906.0
75%	1537.0
max	4000.0

Avant imputation

# energy_100g	
count	40428.0
mean	995.0
std	696.0
min	0.0
25%	372.0
50%	906.0
75%	1532.0
max	4000.0

Après imputation




3 Analyse exploratoire

3 Analyse exploratoire




Répartition des produits par catégorie en pourcentage




3 Analyse exploratoire

Matrice de corrélation suivant le coefficient de spearman




3 Analyse exploratoire



3 Analyse exploratoire




Distribution KDE de energy_100g par groupe de produits



3 Analyse exploratoire



Relation entre énergie et protéines par catégorie





3 Analyse exploratoire


- Analyse en composantes principales

L'ACP a deux objectifs principaux :

- La variabilité entre les individus, c'est-à-dire quelles sont les différences et les ressemblances entre individus ;
- Les liaisons entre les variables : y a-t-il des groupes de variables très corrélées entre elles, qui peuvent être regroupées en de nouvelles variables synthétiques ?




3 Analyse exploratoire



$$Kaiser_{threshold} = 100/n_{components}$$

Les trois premières composantes expliquent 78 % de la variance cumulée.


3 Analyse exploratoire




3 Analyse exploratoire



Projection des groupes de produits sur les axes PC1 et PC2



3 Analyse exploratoire





3 Analyse exploratoire

- ANOVA

Comparer les catégories de produits par rapport à leurs valeurs énergétiques


- Faire des recommandations nutritionnelles.
- Optimiser la classification des produits.
- Identifier des groupes de produits particulièrement énergétiques.



3 Analyse exploratoire

- ANOVA
- Test des conditions d'application de l'ANOVA :
 - Indépendance des produits (individus)
 - Les résidus doivent suivre une loi normal : Test de kolmogorov-smirnov
H0 validée si $p > 5\%$
 - La variance de chaque groupe doit être semblable : Test de bartlett
H0 validée si $p > 5\%$

3 Analyse exploratoire





3 Analyse exploratoire

- ANOVA alternative kruskals-Wallis
- Test des conditions d'application de l'ANOVA :

Hypothèse H_0 est validée si dans les groupes la médiane est la même.

Pour la valeur nutritionnelle energy : $p < 5\%$



3 Analyse exploratoire

- ETA^2 (η^2) pour mesurer l'effet d'une variable catégorielle sur une variable numérique.

Les règles empiriques suivantes sont utilisées pour interpréter les valeurs de Eta au carré :

.01 : Petite taille d'effet

.06 : Taille d'effet moyenne

.14 ou supérieur : grande taille d'effet

- Résultat de ETA^2 pour energy_100g: 0.52



4 Conclusion

- **Protection des données**

Aucune données personnelles ne sera utilisées dans l'algorithme de suggestion

- **Dimension du jeu de données**

40428 produits, 7 valeurs nutritives

Nombre de produits hétérogènes par catégories avec une prédominance des produits sucrés.

Les groupes sont distincts les uns des autres ce qui devrait réduire le nombre de fausses suggestions.